

基于接收波形的 Chiplet 晶粒间互连故障诊断

多模态遥测的价值取决于观测的有损性

VLSI 测试课程 Mini Research Project (方向三: D2D Link 异常检测)

2026 年 6 月

摘要

异构集成 (heterogeneous integration) 把**晶粒间互连** (die-to-die, D2D) 变成了 chiplet 系统的可靠性瓶颈: 单封装内**微凸点** (micro-bump, 连接相邻晶粒的微米级焊点) 数以万计, 且存在大量结构测试无法预见的在役退化模式。本项目以一个纯 `ngspice`、可完全复现的 D2D 链路仿真器为数据源, 构造了包含 10 类故障、786 条样本的**原始接收波形数据集**, 并在其上比较了线性基线¹与一维卷积网络 (1-D CNN) 的诊断能力, 完成了四组实验。

主要结论有三。其一, 在故障覆盖全温度区间的较难数据上, 原始波形上的 CNN 达到 80.3% 的十分类准确率, 显著高于同样读原始波形的逻辑回归 (70.2%), 也高于读 18 维人工眼图特征的浅层模型 ($\leq 70.2\%$) ——说明从原始信号学习表征捕获了固定特征集会丢弃的、依赖位置且随故障而异的结构。其二, 对两类连续漂移故障的严重度回归 R^2 分别达 0.867 与 0.998。其三, 也是本文的核心论点: 温度与电压跌落是与真实故障征象重叠的**良性混杂因子**, **多模态遥测 (温度 / droop) 的价值取决于主观测的有损程度**。当模型可见完整波形时遥测近乎冗余; 而在运行时真正可得的**有损标量观测** (单个眼裕度) 下, 单阈值规则无法兼顾低误报与高检出——在零误报工作点其故障检出率仅 58.7%, 而融合温度的学习边界在同样零误报下达到 72.0%。这把“多模态融合是否有用”从口号变成一个有判决条件的结论, 也直接回应了课程对“AI 何时有效、何时不必要”的要求。

1 引言与背景

1.1 为什么 D2D 互连成为可靠性瓶颈

先进制程的经济性推动系统从单片大芯片走向**多 chiplet 解耦 + 中介层 (interposer) / 桥 (bridge) 重新集成**。单封装内的 D2D 互连数量已从早期产品的不足一千攀升到近年高端产品的近十万, I/O 密度向每平方毫米上万演进, 凸点节距 (pitch, 相邻凸点中心间距) 跌破 $10\mu\text{m}$ 。每一根互连都要穿过微凸点、再分布层 (RDL) 乃至硅通孔 (TSV), 因此一个封装拥有成千上万个相互独立的失效机会。其中相当一部分缺陷只在**部署之后**才显现: 电迁移、C4 凸点的热机械疲劳、晶体管阈值的 NBTI/PBTI 漂移、封装翘曲诱发的成簇缺陷等。

1.2 为什么需要在役 (in-field) 健康评估, 而非仅靠一次性结构测试

工业界对 chiplet 互连的主流测试是**结构测试**: 通过 IEEE 1838 的晶粒包装寄存器加载确定性图案、捕获 pass/fail、用备用 lane 修复。它严谨, 但本质上是**制造时的一次性活动**, 无法观测在役才发展出来的**弱、参数化、漂移、老化**类失效——这些失效表现为时序裕度的缓慢退化而非确定的逻辑错误, 只有持续监测眼裕度、误码率、lane 偏斜的运行实时监控才能捕获。

1.3 混杂：单一健康信号天然有歧义

D2D 链路不是孤立退化的。它的眼裕度与误码率会被**供电跌落**（supply droop，负载瞬变导致的电源电压下陷）与**温度漂移**同时调制：一次温升或一次重负载 droop 都会**闭合眼图**，其征象与真实缺陷重叠。因此，要把“良性环境波动”与“萌生缺陷”区分开，本质上需要把环境共模建模并扣除——这正是本项目要量化研究的核心问题，也是“为什么需要一个能融合多模态信号的统计模型”的根源。

2 问题定义

测试问题。 给定一条 D2D 链路在某工况下采集到的**接收端模拟波形**，自动判别其故障类型（10 类，含“健康”），并对连续退化故障做**严重度回归**；同时回答：当运行时只能得到极有损的观测（如一个眼裕度标量）时，加入片上温度／droop 遥测能否抑制由良性高应力导致的误报。

输入与输出。 输入为一维 RX 波形（128 个**单位间隔**（unit interval, UI，一个比特占据的时间窗，本文 UI= 62.5 ps）× 每 UI 8 个采样 = 1024 点），可选叠加标量遥测 [温度, droop]；输出为 10 类 softmax（诊断）、连续严重度（回归）、或健康/故障二分类（有损检测）之一。

两种观测体制（本文的关键自变量）。

- **完整波形**（诊断/后硅 bring-up 态）：模型可见 1024 点全波形。对应文献中的眼图-CNN、波形自编码器，是片上眼图监测或示波采样可达的信息上限。
- **有损标量**（运行时真实可得）：把波形压成**单一眼裕度标量**，模拟片上裕度寄存器实际能提供的信息。

区分这两种体制是诚实建模的要求，也是核心洞见的来源：原始模拟波形并非运行时遥测，运行时真正可得的是有损的标量/计数。

2.1 故障的判定：未显著恶化 BER/时延的退化算不算故障？

这是一个必须先回答的定义问题。测试理论区分四个概念：**缺陷**（defect，物理瑕疵）、**故障**（fault，缺陷的电学/模型化表现）、**差错**（error，某次输出取值错误）、**失效**（failure，偏离规格的可观测服务中断）。**误码率（BER）抬升或时延越限属于 error/failure 层面，而故障是参数层面的偏离**——二者不是一回事。

本文据此以“**某物理/电学参数偏离其健康分布**”来判定故障，而非以“当前是否已造成显著 BER/时延恶化”来判定。理由有三：

1. **潜伏/萌生故障（latent/incipient fault）**：一个尚未引发误码、但已侵蚀时序与电压裕度的退化，会在老化、温度升高或电压漂移叠加时越过阈值而失效。在役健康监测的价值，恰恰在于**在其演变为 failure 之前就捕获它**——这正是本项目区别于一次性 pass/fail 结构测试的出发点。
2. **BER 是滞后且饱和的指标**：健康链路 $BER \approx 0$ ，许多萌生故障要到很晚才抬升 BER（本仿真在无噪声时 BER 恒为 10^{-300} ，正说明它不能用作早期判据）。因此本文转而读**波形形状**

并对连续故障做 **严重度回归**，在越限阈值以下就量化退化程度（见 r_drift/c_drift 的回归）。

3. 但须与良性环境波动区分：温度/droop 同样压低眼图却不是故障。所以“眼变差”不等于“有故障”；判据是**底层参数是否异常偏移**，而非眼图是否变差——这正是本文混杂去除与根因分类的意义。

结论：在本框架中，一个低严重度、BER 仍 ≈ 0 的 $r_drift/c_drift/bump_void_aging$ 仍算故障（潜伏态），而且是最值得提前检出的对象；反之，一条高温下 BER 略升的健康链路**不算**故障。这一定义使“严重度回归”和“混杂去除”成为问题的内在组成，而非附加项。

为何 AI 适合。 正常工作流形高维、且与工艺-电压-温度(PVT)强相关；标注的现场失效样本稀缺；退化是渐进的。这类“学正常、判偏离 + 多模态去混杂”的问题，与课程推荐的自编码器/LSTM/统计异常检测同源。更具体的“为什么必须用学习模型而不是阈值或人工特征”，将在第 6 节用专门实验回答。

3 仿真数据源与故障建模

3.1 链路仿真器与电路结构

数据源是一个纯 ngspice（无任何商业 EM/AMI 工具）、纯标准库 Python 封装的 D2D 链路仿真器。图 1 给出受害（victim）lane 的等效电路：行为级驱动经温度相关输出电阻 $R_{on}(T)$ 启动一个分段线性（PWL）电压摆，依次穿过发送端微凸点（ $R_b+L_b+C_b$ ）、 $N=20$ 段 **RLGC 阶梯**、接收端微凸点，到达接收节点（RX 焊盘电容 C_{rx} 与轻终端 R_{term} ）。

RLGC 阶梯指把一段分布参数传输线离散为 N 个集总单元，每单元含串联电阻 R_{seg} 、串联电感 L_{seg} 、对地电容 C_{node} （电导 G 在本短链路可忽略），用以近似传输线的频变损耗与时延。每段取自每毫米线参数： $R'=0.35\ \Omega/\text{mm}$ 、 $L'=0.45\ \text{nH}/\text{mm}$ 、 $C'=0.18\ \text{pF}/\text{mm}$ ，线长 2 mm，故 $R_{seg}=0.035\ \Omega$ 、 $L_{seg}=0.045\ \text{nH}$ 、 $C_{node}=0.018\ \text{pF}$ 。相邻两条 **aggressor**（干扰源）lane 通过逐节点耦合电容 C_c （ $C'_c=0.030\ \text{pF}/\text{mm}$ ）注入 **串扰**（crosstalk，邻线翻转经容性耦合在受害线上产生的噪声）。关键工艺参数取 UCIe 级短距低摆幅单端（single-ended, SE）信号： $V_{dd}=0.8\ \text{V}$ ，速率 16 GT/s（故 $UI=62.5\ \text{ps}$ ）， $Z_0=50\ \Omega$ ，导体电阻带铜温度系数 $t_{c1}=3.9 \times 10^{-3}/^\circ\text{C}$ 。

3.2 为支撑本研究而做的三项物理扩展

基础仿真器只能输出干净眼图，不足以表达混杂与连续退化。为此扩展三点：

1. **瞬态电阻热噪声**。在受害 lane 的各电阻上串入 **trnoise**（时域热电动势源），其 RMS 正比于 $\sqrt{4k_B T R \Delta f}$ （Johnson-Nyquist 热噪声， k_B 为玻尔兹曼常数， T 温度， R 电阻， Δf 等效带宽）。物理含义：噪声随 $\sqrt{T}$ 随温度上升（构成混杂），随 $\sqrt{R}$ 随阻性故障上升（故障自带噪声指纹）。这同时修复了无噪声时误码率恒为 10^{-300} 的退化值。
2. **温度相关驱动电阻 $R_{on}(T)$** 。取 $R_{on}(T) = R_{on,0} (T/T_0)^{1.5}$ （迁移率退化）。这是温度闭合一条**匹配良好短链路眼图的主导机制**：本链路导体电阻仅 $0.7\ \Omega$ ，相对 $45\ \Omega$ 驱动电阻与 $80\ \Omega$ 终端可忽略，若不引入 $R_{on}(T)$ ，温度在波形上几乎不可观测。引入后健康**眼高**（eye height，眼图睁开的垂直电压幅度）由 $504\ \text{mV}$ 降至 $419\ \text{mV}$ （ $27 \rightarrow 110^\circ\text{C}$ ）。




图 1: 受害 lane 的 ngspice 等效电路 (单端)。温度相关驱动 $R_{on}(T)$ 启动 PWL 摆; 信号经 TX 微凸点 ($R_b + L_b + C_b$)、 $N=20$ 段 RLGC 阶梯 (逐节点对地电容 C_{node} , 并经 C_c 与相邻 aggressor 耦合)、RX 微凸点, 到达接收节点 ($C_{rx} +$ 终端 R_{term} 接中位电平 $V_{dd}/2$)。故障注入即在指定段位修改 R_{seg} 、 L_{seg} 、 C_{node} 、 C_c 或驱动摆幅 (见表 1)。

3. 连续漂移故障 + 良性可观测 droop。新增 `r_drift` (分布式串联电阻, $[15, 150] \Omega$) 与 `c_drift` (并联电容膨胀), 作为严重度回归目标; 并加入一个**良性、可观测**的工况 droop (记入 `vdroop_frac` 遥测列, 区别于作为故障的 `supply_droop`), 作为第二个混杂因子。

3.3 故障模型: 改变了哪些参数、取值范围如何

每一类故障都对应图 1 中某个具体元件值的改变, 并带一个明确的**严重度轴**。表 1 给出每类故障改变的参数、标称值、故障取值范围与注入位置; 下文再就几类需要展开建模的故障做说明。**眼裕度** (eye margin) 在本文定义为有效区间内波形电平的第 90 与第 10 百分位之差, 近似眼图的垂直张开度。

阻性类 (`resistive_open` / `bump_void_aging` / `r_drift`)。三者共享“串联电阻增大 $\Rightarrow$ 分压衰减 $\Rightarrow$ 幅度下降”的机制, 区别在**空间分布与时间尺度**: `resistive_open` 是单段集总大阻 (突发缺陷, $20\text{--}500 \Omega$, 约为标称段阻的 $10^3\text{--}10^4$ 倍); `bump_void_aging` 是同形式但幅度较小、随老化缓增 ($5\text{--}80 \Omega$, 且只在高温 $85/110^\circ\text{C}$ 取样, 模拟在役热场下的电迁移/空洞); `r_drift` 把总附加阻 ΔR 均分到全部 20 段 ($R_{seg} += \Delta R/N$), 表示整条线均匀老化, $\Delta R \in [15, 150] \Omega$ 提供一条连续严重度轴。

容性类 (`c_drift` / `crosstalk_cap`)。 `c_drift` 把每个对地节点电容乘 $(1+c)$, $c \in [0.3, 2.5]$, 增大充放电时间常数 $\Rightarrow$ 跳变沿变缓、码间串扰 (ISI) 加重, 是第二条连续严重度轴; `crosstalk_cap` 把受害线与两条 aggressor 间的逐节点耦合电容乘 $f \in \{2, 4, 8\}$, 邻线翻转时在受害线平台/沿处注入更强的容性噪声。

反射类 (`impedance_discontinuity`)。在连续 3 段把段电感 L_{seg} 乘 z ($z < 1$ 降阻抗、呈容性; $z > 1$ 升阻抗、呈感性), 形成局部特征阻抗台阶 $Z = \sqrt{L/C}$ 的失配。其能量主要进入**反射**而非幅度衰减, 故在眼图幅度上几乎不可见——这是后文区域消融中它“仅在跳变沿可检、平台区 0.00”的物理根源, 也是单一幅度度量天生覆盖不到的一类。

表 1: 十类故障的注入参数、标称值与取值范围（段编号 $k \in [0, 19]$ ；位置即注入的段下标。连续类 r_drift/c_drift 用方括号给出连续区间，其余为离散级别）

类别	改变的参数	标称值	故障取值（级数）	位置/温度
healthy	无注入	——	——	$T \in \{27, 45, 65, 85, 100, 110\}^\circ\text{C}$
resistive_open	单段串阻 $+r_o$	$0.035\ \Omega$	$r_o \in \{20, 50, 150, 500\}\ \Omega$ (4)	段 5、14
bump_void_aging	单段串阻 $+r_o$ （缓增）	$0.035\ \Omega$	$r_o \in \{5, 20, 40, 80\}\ \Omega$ (4)	段 5; $T \in \{85, 110\}$
bridge_short	并联阻 R_{brg} 到邻线	开路	$R_{brg} \in \{50, 200, 800, 3000\}\ \Omega$ (4)	节点 10
crosstalk_cap	耦合容 $\times f$	$0.003\ \text{pF}$	$f \in \{2, 4, 8\}$ (3)	全部节点
supply_droop	发送摆幅 $\times(1-d)$	$0.8\ \text{V}$	$d \in \{0.05, 0.10, 0.15, 0.20\}$ (4)	驱动
hotspot	5 段局部温 $+ \text{串阻}$	全局 T	$T_{\text{hot}} \in \{120, 150\}^\circ\text{C}$ (2)	段 8–12
impedance_discontinuity	3 段电感 $\times z$	$0.045\ \text{nH}$	$z \in \{0.4, 0.6, 1.8, 3.0\}$ (4)	段 7–9
r_drift	全段串阻 $+\Delta R/N$	$0.7\ \Omega$ 总	$\Delta R \in [15, 150]\ \Omega$ (7)	全段分布
c_drift	全节点容 $\times(1+c)$	$0.018\ \text{pF}$	$c \in [0.3, 2.5]$ (7)	全部节点

3.4 供电跌落（supply droop）的建模

供电跌落（supply droop）指负载电流瞬变在供电网络（PDN）的电阻与电感上产生压降，使驱动看到的电源轨瞬时下陷，从而**降低发送摆幅**、闭合眼图。本数据集用的理想前端把它建为对发送 PWL 摆幅的乘性缩放 $V_{\text{swing}} \leftarrow V_{\text{dd}}(1-d)$ 。需区分两种 droop：

- **良性工况 droop**（混杂因子，非故障）：正常负载活动造成的可观测 IR 压降， $d_{\text{benign}} \in \{0, 0.05, 0.10\}$ ，记入遥测列 `vdroop_frac`。它像衰减类故障一样压低眼图，但属正常工况，是融合模型用来**拒绝误报**的依据。
- **supply_droop 故障**：一次无法由工况解释的、更大的额外跌落 $d \in \{0.05, 0.10, 0.15, 0.20\}$ ，叠加在良性 droop 之上。

（仿真器另有一条行为级有源前端，把 droop 建为显式 PDN：稳压源经 $R_{\text{pdn}}=20\ \text{m}\Omega$ 、 $L_{\text{pdn}}=100\ \text{pH}$ 到去耦电容 $C_{\text{dec}}=50\ \text{nF}$ ，并由一个与数据相关的同步开关电流负载（SSO）真实地把电源轨拉低，产生静态 IR 压降与 $L di/dt$ 首跌振铃。本研究数据集采用理想前端的等效摆幅缩放，以保证大批量仿真的数值稳健与可复现。）

3.5 热点（hotspot）与温度的建模

全局**芯片温度** T 通过 ngspice 的 `.temp` 卡作用于三处：导体电阻经铜温度系数 t_{c1} 升高、驱动输出电阻经 $R_{\text{on}}(T)$ 升高（主导项）、热噪声 RMS 经 $\sqrt{T}$ 升高。**healthy** 与各故障都在 $27\text{--}110^\circ\text{C}$ 取样，使温度成为贯穿所有类的混杂变量而非某类的标志。

hotspot 故障建模一个**局部热区**：在中心段 ± 2 （共 5 段，段 8–12）把这些电阻实例的温度**钉在** $T_{\text{hot}} \in \{120, 150\}^\circ\text{C}$ （高于全局 T ），并叠加一项随过热量增长的局部串阻 $\Delta R_{\text{seg}} =$

$\max(0, (T_{\text{hot}} - 90) \cdot 2) / 5$ （模拟空洞/自热引起的电迁移退化，使该热事件在眼图上可检）。例如 $T_{\text{hot}} = 120^\circ\text{C}$ 时每段加 $12\ \Omega$ 、五段合计 $60\ \Omega$ 。局部温度本身因导体阻很小而影响有限，故 hotspot 的可观测征象主要来自这条局部串阻。

3.6 温度与 droop 遥测“如何被测量”

表 4-6 用到的两路标量遥测，其语义与来源如下：

- 在**仿真**中它们是受控的潜变量：温度即每次仿真设定的 `.temp` 值（按 $27\text{--}110^\circ\text{C}$ 网格扫），良性 droop 即设定的摆幅缩减 d_{benign} ；二者作为**真值**分别写入数据集的 `temp_C`、`vdroop_frac` 两列。它们是“可测但有噪声、与故障征象重叠”的环境共模量，而非故障标签。
- 在**真实芯片**中它们对应成熟的片上监测电路：温度由片上**数字温度传感器**（DTS，基于 BJT/二极管的热敏单元）给出；供电跌落由片上**电压跌落监测器 / 关键路径监测器**（droop monitor / critical-path monitor）给出。也就是说，本文“融合遥测”所需的两路信号在现代 SoC 中本就常态化采集，方法不依赖额外的专用探针。

3.7 数据集

数据集规模 786 条、每条 1024 点。故障跨 **$27/85/110^\circ\text{C}$ 全温度区间**采样——这一点对混杂结论至关重要：若故障只出现在某些温度，模型会学到“高温 $\Rightarrow$ 健康”的标签捷径，混杂结论便成为假象。健康类覆盖 $27\text{--}110^\circ\text{C}$ 的密集温度网格。每个（故障，参数，温度）组合用 6 个不同的噪声种子重复（并循环施加 3 档良性 droop），所有样本共用同一条 **PRBS**（伪随机比特序列）发送图案（固定随机种子），使故障与噪声成为唯一变化源，并使“跳变沿区/稳态平台区”的掩膜对所有样本一致。单条波形仿真加重采样约 1.2s ，全数据集约 16min ；脚本公开，无需任何工业数据。

图 2 给出每类故障的眼图：健康为清晰睁开的眼，阻性/droop 类幅度坍塌，`c_drift` 沿变缓，`crosstalk` 模糊，`impedance_discontinuity` 在幅度上几乎不可见。

4 方法：诊断如何进行

本节详细说明诊断的完整数据通路、模型结构、前向计算与三组消融的设计，使流程可被精确复现。

4.1 从波形到判决的完整通路

- 步骤 1. 采集与重采样。**对每次仿真，取受害 lane 接收节点电压 $v(t)$ ，用线性插值重采样到统一栅格 $t_k = k \cdot (\text{UI}/8)$ ， $k = 0, \dots, 1023$ 。统一栅格保证所有样本等长、且比特相位一一对齐，从而后续的区域掩膜对所有样本一致。
- 步骤 2. 标准化。**以训练集的全局均值与标准差对波形做 z -标准化，消除整体幅度尺度，使模型关注形状。
- 步骤 3. 有效区裁剪。**丢弃前 `settle_bits` 个用于填充信道的比特，仅保留稳态有效区（960 点）。
- 步骤 4. 特征提取（卷积干路）。**见 §4.2。
- 步骤 5. 判决头。**卷积特征（可选拼接遥测）经两层多层感知机（MLP）映射到 10 维 logit，取 softmax 后 `argmax` 即为预测类别；严重度回归则换成单一线性输出 + 均方误差。




图 2: 每类故障的接收端眼图 (折叠 2 UI)。阻抗不连续属反射域故障, 在幅度域几乎不可见, 对应后文区域消融中其“平台区准确率 0.00”的结果。

4.2 卷积网络结构与前向计算

诊断主模型是一维 CNN, 结构如下 (输入为 1×960 的单通道波形):

$$\text{Conv1d}(1 \rightarrow 16, k=7) \rightarrow \text{ReLU} \rightarrow \text{MaxPool}_2 \rightarrow \text{Conv1d}(16 \rightarrow 32, k=5) \rightarrow \text{ReLU} \rightarrow \text{MaxPool}_2 \rightarrow \\ \text{Conv1d}(32 \rightarrow 64, k=3) \rightarrow \text{ReLU}$$

随后在时间维上做平均池化与最大池化并拼接得到 128 维向量:

$$\mathbf{f} = \left[\underbrace{\frac{1}{T} \sum_t z_{:,t}}_{64 \text{ 维, 均值}} \parallel \underbrace{\max_t z_{:,t}}_{64 \text{ 维, 极值}} \right] \quad (\parallel \text{ 表示拼接}).$$

拼接两种池化的动机有明确物理含义: **平均池化**保留稳态电平/幅度指纹 (阻性、droop 类故障的判别信息在此), **最大池化**保留峰值与跳变沿信息 (串扰、阻抗不连续的信息在此)。仅用全局平均池化会把波形塌缩为均值、丢失幅度与极值的区分——实测中这正是早期 CNN 不如线性基线的原因。随后 (若启用遥测融合) 把标量遥测 [温度/100, droop $\times 10$] 拼到 $\mathbf{f}$ 后, 经 $\text{Linear}(128(+2) \rightarrow 64) \rightarrow \text{ReLU} \rightarrow \text{Linear}(64 \rightarrow 10)$ 得到 logit。

训练细节。 交叉熵损失采用**逆频率类权重** (健康等少数类被加权), Adam 优化器 ($\text{lr} = 2 \times 10^{-3}$, 权重衰减 10^{-4}), 120 个 epoch, 批大小 32。数据按类别分层 75/25 划分 (训练 588 / 测试 198),

随机种子固定。

4.3 循环网络 (LSTM) 对照

波形本质是时间序列，因此课程推荐的另一类模型——**LSTM**（长短期记忆网络，一种带门控记忆单元、能沿时间逐点累积状态的循环神经网络）——是 CNN 之外的自然选择。我们以相同的有效区波形为输入训练一个 2 层 LSTM（隐藏维 64，沿时间每 2 个采样取 1 个以控制序列长度），取末层最后时刻的隐藏状态经同样的两层 MLP 头输出类别；可选地在 MLP 头处拼接温度/droop 遥测。CNN 与 LSTM 的差异在归纳偏置：CNN 用**平移不变的局部卷积核 + 池化**抓取“波形某处的局部形状”，LSTM 用**时序递归**抓取“沿时间累积的依赖”。二者的对比用于检验结论不依赖单一架构。

4.4 对照方法

- **线性基线**：多项逻辑回归，输入为标准化后的原始波形（或标量），输出为类别。它衡量“故障是否线性可分”。
- **人工特征基线** (§6 新增)：不读原始波形，而是抽取 18 维标准眼图特征（均值电平、眼裕度、标准差、最大压摆率、第 10/90 百分位，分别在全/沿/平台三区计算），训练同样的逻辑回归与一个小 MLP。它衡量“从原始信号学表征相比经典特征工程是否更优”。
- **单阈值规则** (§6 新增)：有损体制下，模拟测试工程师最自然的非学习替代——“若眼裕度 $< \tau$ 则判为故障”。

4.5 三组消融的设计

- **遥测消融**：A（仅波形）对 B（波形 + 温度/droop），在**两种观测体制**下分别做，比较总体准确率、高应力子集准确率、健康误报率。
- **区域消融**：分别仅用**沿区**（跳变沿 ± 0.5 UI 窗）、仅用**平台区**、与全波形训练 CNN（掩膜由固定比特序列导出，对所有样本一致），定位“故障特征住在波形何处”；为稳健起见对每种区域做 3 次重初始化取均值 $\pm$ 标准差。
- **严重度回归**：在 `r_drift/c_drift` 子集上，用同一卷积干路换单输出 + MSE，预测归一化严重度。

5 实验结果

5.1 故障诊断（10 类，测试集 $n = 198$ ）

CNN 较所有浅层/人工特征方法高约 10 个百分点，也明显高于 LSTM。**LSTM 反而低于 CNN** (0.596 对 0.803)：判别信息是“波形特定相位处的局部形状”，CNN 的平移不变卷积核加池化能直接抓取，而 LSTM 须把约 480 步序列压进末时刻隐藏状态、易丢失精确的局部幅度，且在 588 条样本上更难训练。这与课程“不卷模型、归纳偏置要匹配信号”的导向一致：合适的结构（CNN）比更复杂的结构（LSTM）更重要。表首两行（单标量 0.222、多数类 0.182）将在第 6 节用于回答“常规方法只能做二分类、而学习模型能给出根因”这一命题。混淆矩阵（图 3）显示 `crosstalk`、

表 2: 十分类诊断结果（测试集）。macro-F1 为各类 F1 的非加权平均，对类不平衡更敏感

模型	准确率	macro-F1
单一眼裕度标量 + 逻辑回归	0.222	0.209
多数类基线 (floor)	0.182	——
人工眼图特征 (18 维) + 逻辑回归	0.672	——
人工眼图特征 (18 维) + MLP	0.702	——
逻辑回归 (原始波形)	0.702	——
LSTM (原始波形)	0.596	0.575
1-D CNN (原始波形)	0.803	0.788

c_drift 近乎完美；几类串阻幅度故障 (resistive_open/r_drift/bump_void_aging) 之间存在可理解的混淆。




图 3: CNN 在原始波形上的混淆矩阵。串阻类之间的混淆源于它们共享“幅度下降”这一征象。

5.2 严重度回归

c_drift 严重度几乎完美可回归；r_drift 略低，因其与温度同样表现为串阻、存在轻度混杂（这一混杂正是下一节遥测价值的根源）。

5.3 遥测消融：多模态融合的价值取决于观测的有损性

这个实验回答什么、不回答什么。需要先澄清，以免误读：本小节回答的是“在什么条件下，融合温度/droop 这类环境遥测才有用”——这是一个关于观测与数据融合的问题，不是“为什么需要机器学习”的问题（后者在第 6 节用独立实验回答）。两者是正交的：前者关乎问题为何难（环境共模使健康信号产生歧义），后者关乎解法为何要用学习模型。

表 3: 连续漂移故障的严重度回归

故障	归一化 MAE	R^2
r_drift (分布式串阻)	0.107	0.867
c_drift (并联电容)	0.012	0.998

还需说明，温度能闭合眼图不是我们为了制造结论而人为设的数据假象，而是一个有物理依据的机制：温度升高使载流子迁移率退化、驱动输出电阻 $R_{on}(T)$ 上升 (§3.5)，这在真实低摆幅链路中确实会压低眼幅。我们做的只是把这个真实的混杂显式建进仿真，再问“当主观测有损时，遥测能否把它扣除”。因此结论是关于融合价值的、而非关于数据生成方式的。

表 4: 遥测消融：A（仅信号）对 B（信号 + 温度/droop），两种观测体制。FA 指误报率

观测体制	方法	总体准确率		健康误报率	
		A	B	A	B
完整波形	波形 / + 遥测	0.803	0.864	0.333	0.333
有损标量眼裕度	裕度 / + 遥测	0.707	0.732	0.375	0.000

注：有损体制的健康误报率为“高应力健康”子集（温度 $\geq 85^\circ\text{C}$ 或 droop $\geq 5\%$ ）上的误报。

完整波形已隐含温度/droop（它们闭合眼图），故遥测多为冗余、仅小幅提升总体；而在运行时只剩一个眼裕度标量时，良性高应力链路与真实故障在该标量上重叠（图 4 灰带区），单看裕度必然误报，加入温度/droop 后误报被完全消除。这正是多模态融合在 D2D 在役监测中的价值边界。




图 4: 有损观测下的混杂分离。横轴是运行时唯一可得的眼裕度标量，纵轴是温度遥测。灰带内健康（绿）与故障（红）在裕度上重叠——任何单一裕度阈值都无法分开；加入温度这一维后二者可分。

表 5: 区域消融 (3 次重初始化, 均值 $\pm$ 标准差)

训练所用区域	准确率
全波形	0.806 ± 0.019
仅沿区 (signal)	0.785 ± 0.023
仅平台区 (held)	0.660 ± 0.041

5.4 区域消融：判别信息住在波形何处

总体上故障信息集中在**跳变沿**（沿区 $\approx$ 全波形 $\gg$ 平台区）。更有信息量的是逐类分布（图 5）：**impedance_discontinuity** 沿区 0.94 / 平台区 **0.00**——反射型故障只在沿处现形，印证其属反射域、需 TDR（时域反射）或多探针才能覆盖；**healthy** 平台区 1.00——干净稳态电平最具判别力。不同故障的判别信息分布在波形的不同部位，这为“片上比较器最佳采样位置/多探针布置”提供了可计算的经验证据，也解释了为何固定的少量人工特征会受限（见下节）。




图 5: 区域消融。左：总体准确率；右：逐类准确率。阻抗不连续仅在沿区可检，健康在平台区最可分。

6 技术分析：AI 为什么是必要的

课程要求重点讨论“AI 为什么有效、以及其局限性”。仅凭 CNN 比逻辑回归高 10 个百分点不足以论证“必须用学习模型”——一个测试工程师会反问：为什么不用一个眼裕度阈值，或几条人工特征规则？本节用三组针对性实验回答，给出 AI 必要性的可证伪边界。

与上一节的区分，以及对“是否只是数据生成的结果”的回应。 §5.3 的遥测消融回答的是融合问题（多模态遥测何时有用），其结论依赖于我们注入的温度混杂。本节回答的是解法问题（为什么必须用学习模型），并刻意让其中两组实验**不依赖任何注入的混杂**，以免“AI 必要性”的结论被质疑为数据生成的副产品：

- 实验二（人工特征 vs 学表征）与实验三（单标量能否给出根因）**完全不涉及温度/droop 混杂**——它们只问“把波形压成固定特征或单个标量会丢多少可分性”，这是**故障物理本身**的性质，与我们如何注入环境量无关。这两组是 AI 必要性的**主证据**。

- 实验一（单阈值规则 vs 学习边界）**确实**用到该混杂——它展示的是“混杂存在时一维阈值不够”，故其前提是 §5.3 已论证的、物理上成立的混杂。我们如实标注这一依赖。

6.1 实验一：单阈值规则在有损体制下存在不可逾越的误报-检出权衡

我们给单阈值规则**最大的便利**：直接在测试集上枚举所有候选阈值 τ 选最优（这是任何单阈值规则的性能上界，即“先知阈值”）。结果（表 6）揭示一个结构性困难：

表 6：有损体制：先知单阈值规则对学习的二维（裕度, 温度）边界

检测器	工作点	故障检出率	健康误报率
单阈值规则（先知 τ ）	强制健康误报 = 0	0.587	0.000
单阈值规则（先知 τ ）	最高准确率点	0.995	1.000
学习边界（裕度 + 温度）	自然工作点	0.720	0.000

解读如下。单阈值规则**没有任何工作点能同时做到低误报与高检出**：要把健康误报压到 0，阈值必须放到 414 mV，此时故障检出率崩到 58.7%；反之“最高准确率”那一点之所以好看，只是因为测试集里故障占多数，把几乎所有链路都判为故障（检出率 0.995、误报率 1.0）就能蒙到高准确率——这是一个无用的检测器。根本原因是**良性高应力健康链路**与**真实故障在裕度这一维上重叠**（图 4 灰带），一维阈值在数学上无法表达分隔它们所需的边界。

而一个仅多用了一维**温度遥测**的学习边界，在**同样零误报**下把检出率从 58.7% 提到 72.0%——严格优于规则的零误报工作点。这说明此处 AI 的必要性**不是**“深度网络比线性强”，而是**问题本身需要一个多变量决策边界来扣除混杂**，任何固定的单变量规则都做不到。这是一个有判决条件、可证伪的结论。

6.2 实验二：从原始信号学表征优于固定的人工特征

表 2 已给出：18 维标准眼图特征配逻辑回归/MLP 只能到 0.672/0.702，与读原始波形的逻辑回归持平，而原始波形上的 CNN 达 0.803。也就是说，**把波形压成一组固定的、为单一故障设计的眼图特征会丢信息**。区域消融解释了原因：不同故障的判别信息分布在波形的不同部位（阻抗不连续只在沿，健康只在平台，串阻在幅度），**一组固定的少量特征无法同时为所有故障保留正确的、依赖位置的统计量**；而卷积核在整条波形上滑动、由数据决定关注何处，因而多拿到约 10 个百分点。这正是“从原始信号学表征”相对“经典特征工程”的价值所在，也与课程“不卷模型、看是否真解决问题”的导向一致——价值来自表征学习覆盖了多类故障，而非堆叠层数。

6.3 实验三：常规方法只能二分类，学习模型才能给出根因

一个常被陈述的命题是：常规方法只能判“连接是否有故障”（二分类），而机器学习能进一步分出故障的根因。这一命题在本任务中**基本成立，但需限定**。我们把常规在役监测能拿到的信息——单一眼裕度标量——直接用于 **10 类根因**判别，与学习模型对比（表 7）。

单一眼裕度标量做 10 类只有 **0.222**，几乎等同多数类基线 0.182——也就是说，它携带的**根因信息接近于零**：一个标量裕度可以告诉你“眼闭了多少”（粗略的健康/故障二分），但**无法分辨眼是被串阻、电容、串扰还是反射闭合的**，因为这些不同根因可以塌缩到相同的裕度值。加上温

表 7: 用不同信息做 10 类根因判别 (测试集)。多数类基线为 0.182

判别所用信息	10 类准确率	macro-F1
单一眼裕度标量	0.222	0.209
眼裕度 + 温度/droop 遥测	0.258	0.255
完整波形 (CNN)	0.803	0.788

度/droop 遥测也只升到 0.258 (遥测帮的是去混杂、不是辨根因)。而完整波形的形状 (沿的快慢、平台的噪声、反射纹路) 保留了区分根因所需的结构, CNN 据此达到 0.803。

因此命题应精确表述为: 在“有损标量观测”这一常规在役设置下, 可得信息只够支撑二分类 (且如实验一所示, 连这个二分类在混杂下都不可靠); 要把判别从“是否故障”推进到“何种根因”, 必须使用保留波形结构的观测 + 学习模型。需要说明的边界是, 这并非说一切常规方法都只能二分类——制造测试中基于确定性图案与故障字典的诊断本可做一定的故障定位/分类; 但那依赖结构化激励与响应, 不适用于本文研究的、在混杂下从单一健康信号做在役参数化诊断的设置。

6.4 综合: AI 的必要性边界

合并三组实验, 可以精确陈述 AI 在本任务中“何时必要、何时不必要”:

- 当观测有损 (运行时标量) 且存在混杂: 必须用能表达多变量边界的学习模型来扣除环境共模; 单阈值规则在零误报下损失约 13 个百分点的检出率。
- 当要从“是否故障”推进到“何种根因”: 单标量裕度的 10 类准确率仅 0.222 (约等于瞎猜), 必须用保留波形结构的观测 + 学习模型 (CNN 0.803)。这是“常规 = 二分类、学习 = 根因”命题的量化依据。
- 当需要覆盖多类、信息分布在波形不同位置的故障: 从原始信号学表征优于固定人工特征约 10 个百分点; 且结构要匹配信号——CNN (0.803) 优于 LSTM (0.596), 并非越复杂越好。
- 当观测无损 (完整波形): 波形已隐含混杂变量, 额外遥测近乎冗余; 此时“多加遥测总更好”的直觉不成立。这条边界本身就是本文要传达的洞见。

7 局限性

1. 匹配良好的短链路对参数/热扰动天生迟钝: 导体电阻远小于驱动 + 终端, 故温度、分布式串阻、热点、阻抗阶跃在原始眼幅上长期不可见, 必须显式引入 $R_{on}(T)$ 、绝对分布式串阻等机制才使其可检。这本身也是一条物理洞见: 单一眼图度量对这类退化天生不敏感。
2. 阻抗不连续在幅度域几乎不可见 (平台区准确率 0.00), 属反射域故障, 需 TDR/反射系数模态——进一步印证多模态/多探针的必要性。
3. 原始波形并非运行时遥测: 本文据此区分两种观测体制并诚实标注; 运行时的真实形态是有损标量或误码序列。
4. r_drift 与温度混杂: 分布式串阻与温度同样抬升串阻, 单波形难以完全分离其严重度 (R^2 $0.867 < c_drift$ 0.998), 需遥测辅助。
5. 数据规模与单次划分: 786 样本、单次分层划分 (区域消融已用 3 次重初始化稳健化); 类别

不平衡用类权重缓解；全为仿真数据，缺乏现场标定。

6. **CNN 相对线性基线优势有限**：在更易的数据版本上两者几乎持平，符合课程导向——本工作的贡献在 **问题重构与洞见**，而非新模型。

8 结论与复现

8.1 结论

本项目交付了一个开放、可复现、物理接地的 D2D 互连原始波形故障诊断基准与方法：CNN 十分类诊断 80.3%、连续漂移严重度回归 R^2 0.867/0.998。核心贡献是把“多模态遥测是否有用”变成一个有判决条件的结论——**其价值取决于主观测的有损性**：在有损观测下，融合温度把良性高应力误报从 37.5% 压到 0%，且在零误报工作点把检出率从规则的 58.7% 提到 72.0%；同时区域消融定位了各类故障的判别信息所在（沿区为主，阻抗不连续仅见于沿区）。这是对“在役 D2D 链路健康多模态融合”空白的一个问题重构 + 可证伪演示式的贡献，而非一个新的 ML 模型。

8.2 未来工作

用有损误差序列（比较器位流）替代标量裕度，做时序模型（TCN/LSTM）对照；接入 TDR/反射系数模态覆盖阻抗不连续；多故障共现（multi-label）；扩大样本与多次交叉验证、加入更真实的失配/有损信道标定。

8.3 复现说明

```
cd sim
# 1) 生成原始波形数据集（约 16 min）
python3 -c "from d2dsim.wave_campaign import run_wave_campaign; \
\run_wave_campaign(out_dir='out/wave')"
# 2) 可视化（眼图/波形/遥测覆盖）
~/miniconda3/envs/drl_hw2/bin/python inspect_waves.py --data out/wave
# 3) 训练 + 全部消融 + 出图
~/miniconda3/envs/drl_hw2/bin/python ml_diagnose.py --data out/wave
# 4) “AI 为什么必要”的对照实验（规则基线 + 人工特征基线）
~/miniconda3/envs/drl_hw2/bin/python why_ai.py --data out/wave
# 5) LSTM 对照 + 单标量根因判别实验
~/miniconda3/envs/drl_hw2/bin/python extra_models.py --data out/wave
```

仿真器为纯 ngspice+ 标准库（d2dsim/）；ML 在 drl_hw2 环境（numpy/torch/matplotlib）。关键产物：out/wave/waveforms.csv、results.json、why_ai.json、plots/*.png、inspect/*.png。